

# Fondamenti di Machine Learning

La Regressione

## **Introduzione alla regressione lineare semplice**

presentato da  
Giuseppe Gullo

PROFESSION 

# La regressione lineare semplice

Ci permette di trovare una relazione lineare tra una variabile indipendente (feature) e una variabile dipendente (target).

Metri quadri	Valore in €
80	160.000
150	300.000
30	120.000
50	100.000
120	240.000
60	180.000
110	200.000
110	250.000
70	???
60	???

# La regressione lineare

Dataset di monolocali a Milano

Metri quadri	Valore in €
80	160.000
150	300.000
30	120.000
50	100.000
120	240.000
60	180.000
110	200.000
110	250.000
70	???
60	???

# La regressione lineare

Dataset di monolocali a Milano

← Quanto valgono questi appartamenti?

x	y
80	160.000
150	300.000
30	120.000
50	100.000
120	240.000
60	180.000
110	200.000
110	250.000
70	???
60	???

# La regressione lineare

Dataset di monolocali a Milano

$x$

x	y
80	160.000
150	300.000
30	120.000
50	100.000
120	240.000
60	180.000
110	200.000
110	250.000
70	???
60	???

# La regressione lineare

Dataset di monolocali a Milano

$x$

$y$


Metri quadri	Valore in €
80	160.000
150	300.000
30	120.000
50	100.000
120	240.000
60	180.000
110	200.000
110	250.000
70	???
60	???

# La regressione lineare

Dataset di monolocali a Milano


$$f(x) = y$$

# Rappresentazione grafica del dataset






# Rappresentazione grafica del dataset




# Rappresentazione grafica del dataset



**Equazione di una retta**  
(forma esplicita)

$$y = q + mx$$

# Rappresentazione grafica del dataset




## Equazione di una retta (forma esplicita)

$$y = q + mx$$

Diagram illustrating the components of the linear equation  $y = q + mx$ :

- $y$  is labeled **VARIABILE DIPENDENTE** (Dependent Variable).
- $q$  is labeled **INTERCETTA** (Intercept).
- $m$  is labeled **COEFFICIENTE (ANGOLARE)** (Angular Coefficient).
- $x$  is labeled **VARIABILE INDIPENDENTE** (Independent Variable).

# Rappresentazione grafica del dataset




## Equazione di una retta (forma esplicita)

$$y = \underline{q} + mx$$

L'intercetta stabilisce  
la distanza della retta  
dall'origine.

Quindi funge da **bias**.


# Rappresentazione grafica del dataset



Equazione di una retta  
(forma esplicita)

$$y = \underset{\uparrow}{\underline{q}} + mx$$


# Rappresentazione grafica del dataset



Equazione di una retta  
(forma esplicita)

$$y = \underline{q} + mx$$

# Rappresentazione grafica del dataset




Equazione di una retta  
(forma esplicita)

$$y = q$$

Se il coefficiente angolare è pari a 0,  
vuol dire che la feature non ha  
nessun impatto sul target

# Rappresentazione grafica del dataset



## Equazione di una retta (forma esplicita)


$$y = q + \underline{m}x$$

Il coefficiente angolare stabilisce l'impatto che una variazione della variabile indipendente ha sulla variabile dipendente.

Quindi funge da **peso**




# Rappresentazione grafica del dataset



Equazione di una retta  
(forma esplicita)

$$y = q + \overset{\uparrow}{\underline{m}}x$$


# Rappresentazione grafica del dataset



Equazione di una retta  
(forma esplicita)

$$y = q + \underset{\text{red arrow}}{\underline{m}}x$$

# Rappresentazione grafica del dataset




Equazione di una retta  
(forma esplicita)

$$y = b + wx$$

Diagram illustrating the components of the linear regression equation:

- $y$  is labeled **PREVISIONE** (Prediction).
- $b$  is labeled **BIAS** (Bias).
- $w$  is labeled **PESO** (Weight).
- $x$  is labeled **FEATURE** (Feature).

# Rappresentazione grafica del dataset



**Equazione di una retta**  
(forma esplicita)

$$y = 5.5 + 0.16x$$


Metri quadri	Valore in €
80	160.000
150	300.000
30	120.000
50	100.000
120	240.000
60	180.000
110	200.000
110	250.000
70	???
60	???

# La regressione lineare

Dataset di monolocali a Milano

← Quanto valgono questi appartamenti?


# Rappresentazione grafica del dataset



**Equazione di una retta**  
(forma esplicita)

$$5.5 + 0.16 \cdot 70 = 16.7$$

# Rappresentazione grafica del dataset



**Equazione di una retta**  
(forma esplicita)

$$5.5 + 0.16 \cdot 60 = 15.1$$

# Fondamenti di Machine Learning

La Regressione

## **il Metodo dei Minimi Quadrati**

presentato da  
Giuseppe Gullo

PROFESSION 



## il Metodo dei Minimi Quadrati

E' un metodo numerico che ci permette di stimare il valore dei coefficienti di un modello di regressione lineare.

## il Metodo dei Minimi Quadrati

E' un metodo numerico che ci permette di stimare il valore dei coefficienti di un modello di regressione lineare.


Lo fa trovando i coefficienti che minimizzano l'errore del modello.


Metri quadri	Valore in €
80	160.000
150	300.000
30	120.000
50	100.000
120	240.000
60	180.000
110	200.000
110	250.000
70	???
60	???


## Set di dati


## Dati di addestramento

Metri quadri	Valore in €
80	160.000
150	300.000
30	120.000
50	100.000
120	240.000
60	180.000
110	200.000
110	250.000










## I residui

x	y	previsione
80	16	18.3
150	30	29.5
30	12	10.3
50	10	13.5
120	24	24.7
60	18	15.1
110	20	23.1
110	25	23.1





## I residui

x	y	previsione	residui
80	16	18.3	-2.3
150	30	29.5	0.5
30	12	10.3	1.7
50	10	13.5	-3.5
120	24	24.7	-0.7
60	18	15.1	2.9
110	20	23.1	-3.1
110	25	23.1	1.9

## Funzione di costo (Cost Function)

Somma dei quadrati residui (RSS)

$$RSS = \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

## Funzione di costo (Cost Function)

Somma dei quadrati residui (RSS)

$$RSS = \sum_{i=1}^N (y_i - f(x))^2$$

## Funzione di costo (Cost Function)

Somma dei quadrati residui (RSS)

$$RSS = \sum_{i=1}^N (y_i - wx + b)^2$$


## Funzione obiettivo (Objective Function)

$$L(w, b) = \sum_{i=1}^N (y_i - \underline{w}x + \underline{b})^2$$

Dobbiamo trovare i valori di  $w$  e  $b$   
che minimizzano la somma dei quadrati residui.

# Ottimizzazione matematica

L'ottimizzazione è una branca della matematica applicata che studia teoria e metodi per la ricerca dei punti di massimo e minimo di una funzione matematica all'interno di un dominio specificato.



## Dati di addestramento

x	y
80	160.000
150	300.000
30	120.000
50	100.000
120	240.000
60	180.000
110	200.000
110	250.000

$$wx + b = y$$

# il Metodo dei Minimi Quadrati in Pratica

x	y	xy	x <sup>2</sup>
80	16	1280	6400
150	30	4500	22500
30	12	360	900
50	10	500	2500
120	24	2880	14400
60	18	1080	3600
110	20	2200	12100
110	25	2750	12100



## il Metodo dei Minimi Quadrati in Pratica

x	y	xy	x^2
80	16	1280	6400
150	30	4500	22500
30	12	360	900
50	10	500	2500
120	24	2880	14400
60	18	1080	3600
110	20	2200	12100
110	25	2750	12100

$$\sum x = 710$$

$$\sum y = 155$$

$$\sum xy = 15550$$

$$\sum x^2 = 74500$$

$$n = 8$$

# il Metodo dei Minimi Quadrati in Pratica

## Peso

$$\underline{w}x + b = y$$

---

$$w = \frac{n \sum xy - \sum x \sum y}{n \sum x^2 - (\sum x)^2}$$

# il Metodo dei Minimi Quadrati in Pratica

**Peso**

$$\underline{w}x + b = y$$

---

$$w = \frac{8 \cdot 15550 - 710 \cdot 155}{8 \cdot 74500 - (710)^2}$$

# il Metodo dei Minimi Quadrati in Pratica

**Peso**

$$\underline{w}x + b = y$$

---

$$w = 0.16$$

# il Metodo dei Minimi Quadrati in Pratica

## Bias

$$0.16x + \underline{b} = y$$

---

$$b = \frac{\sum y - w \sum x}{n}$$

# il Metodo dei Minimi Quadrati in Pratica

## Bias

$$0.16x + \underline{b} = y$$

---

$$b = \frac{155 - 0.16 \cdot 710}{8}$$

## il Metodo dei Minimi Quadrati in Pratica

**L'equazione lineare del modello**

$$0.16x + 5.5 = y$$

## il Metodo dei Minimi Quadrati in Pratica

**L'equazione lineare del modello**

$$0.16x + 5.5 = y$$



Metri quadri	Valore in €
80	160.000
150	300.000
30	120.000
50	100.000
120	240.000
60	180.000
110	200.000
110	250.000
70	???
60	???

$$0.16 \cdot 70 + 5.5 = 16.7$$

Metri quadri	Valore in €
80	160.000
150	300.000
30	120.000
50	100.000
120	240.000
60	180.000
110	200.000
110	250.000
70	167.000
60	???

$$0.16 \cdot 70 + 5.5 = 16.7$$

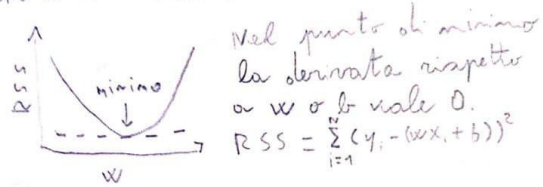
Metri quadri	Valore in €
80	160.000
150	300.000
30	120.000
50	100.000
120	240.000
60	180.000
110	200.000
110	250.000
70	167.000
60	151.000

$$0.16 \cdot 60 + 5.5 = 15.1$$

# METODO DEI MINIMI QUADRATI STEP BY STEP

## OBIETTIVO

Trovare i valori di pesi e bias che minimizzano l'RSS.



## PASSAGGI

1) Esprimiamo l'RSS in funzione di  $w$  e  $b$

$$L(w, b) = \sum_{i=1}^N (y_i - (wx_i + b))^2$$

QUADRATO  
PIÙ  
TRAVOLTO

$$= \sum_{i=1}^N (w^2 x_i^2 + 2bw x_i + b^2 - 2wx_i y_i - 2by_i + y_i^2)$$

$$= w^2 \sum x_i^2 + 2bw \sum x_i + nb^2 - 2w \sum x_i y_i - 2b \sum y_i + \sum y_i^2$$

2) Calcoliamo le derivate parziali rispetto a  $w$  e  $b$

$$\frac{\partial L}{\partial w} = 2w \sum x_i^2 + 2b \sum x_i - 2 \sum x_i y_i$$

$$= w \sum x_i^2 + b \sum x_i - \sum x_i y_i$$

$$\frac{\partial L}{\partial b} = \sum x_i w + \sum nb - \sum y_i = w \sum x_i + nb - \sum y_i$$

3) Poniamo le equazioni ottenute a 0 e ricaviamo  $w$  e  $b$ .

$$w \sum x_i + nb - \sum y_i = 0$$

$$\Rightarrow \boxed{b = \frac{\sum y_i - w \sum x_i}{n}}$$

Sostituiamo  $b$  in  $\frac{\partial L}{\partial w}$  e risolviamo

$$w \sum x_i^2 + \frac{(\sum y_i - w \sum x_i) \sum x_i}{n} - \sum x_i y_i = 0$$

$$\Rightarrow n w \sum x_i^2 + (\sum y_i - w \sum x_i) \sum x_i - n \sum x_i y_i = 0$$

$$\Rightarrow n w \sum x_i^2 + \sum x_i \sum y_i - w (\sum x_i)^2 - n \sum x_i y_i = 0$$

$$\Rightarrow n w \sum x_i^2 - w (\sum x_i)^2 = n \sum x_i y_i - \sum x_i \sum y_i$$

$$\Rightarrow w (n \sum x_i^2 - (\sum x_i)^2) = n \sum x_i y_i - \sum x_i \sum y_i$$

$$\Rightarrow \boxed{w = \frac{n \sum x_i y_i - \sum x_i \sum y_i}{n \sum x_i^2 - (\sum x_i)^2}}$$

Come ricavare le formule?

## Come ricavare le formule?

Se vuoi approfondire ed hai delle buone basi di analisi matematica, guarda l'approfondimento in allegato con tutti i passaggi.

## Come ricavare le formule?

$$w = \frac{n \sum xy - \sum x \sum y}{n \sum x^2 - (\sum x)^2} \quad b = \frac{\sum y - w \sum x}{n}$$

## Come ricavare le formule?

1. Partiamo dalla somma dei quadrati residui

$$RSS = \sum_{i=1}^N (y_i - wx + b)^2$$

## Come ricavare le formule?

2. Calcoliamo le derivate parziali rispetto a peso e bias

$$\delta w = w \sum x^2 + b \sum x - \sum xy$$

$$\delta b = w \sum x + bn - \sum y$$



## Come ricavare le formule?

3. Risolviamo le equazioni per  $w$  e  $b$ .

$$w = \frac{n \sum xy - \sum x \sum y}{n \sum x^2 - (\sum x)^2}$$

$$b = \frac{\sum y - w \sum x}{n}$$

# Fondamenti di Machine Learning

La Regressione


## **Le funzioni di costo**

presentato da  
Giuseppe Gullo

PROFESSION 


# Le funzioni di costo

Permettono di quantificare la capacità predittiva del modello



## I residui

x	y	previsione	residui
80	16	18.3	-2.3
150	30	29.5	0.5
30	12	10.3	1.7
50	10	13.5	-3.5
120	24	24.7	-0.7
60	18	15.1	2.9
110	20	23.1	-3.1
110	25	23.1	1.9





## Errore assoluto medio (MAE)

Il MAE è definito come  
la media della somma  
del valore assoluto dei residui

## Errore assoluto medio (MAE)

$$MAE = \frac{1}{n} \sum_{i=1}^N |y_i - f(x_i)|$$






## Errore assoluto medio (MAE)

$$MAE = \frac{1}{n} \sum_{i=1}^N |y_i - f(x_i)|$$


Valore corretto                  Previsione del modello



## Errore assoluto medio (MAE)

Fornisce un'indicazione di quanto mediamente il modello si è sbagliato






## Errore assoluto medio (MAE)


$$MAE = 2.075$$

Mediamente il modello sbaglia di 20.750 €



## Errore quadratico medio (MSE)

Il MSE è definito come la media della somma dei quadrati dei residui





## Errore quadratico medio (MSE)

$$MSE = \frac{1}{n} \sum_{i=1}^N (y_i - f(x_i))^2$$

## Errore quadratico medio (MSE)


$$MSE = 5.35$$






## Errore quadratico medio (MSE)

Da un peso maggiore ai residui maggiori, cioè agli errori più grandi del modello.




## Somma dei quadrati residui (RSS)

La RSS è definita come la somma degli errori al quadrato per ogni punto del nostro dataset



Somma dei quadrati residui  
(RSS)


$$RSS = \sum_{i=1}^N (y_i - f(x_i))^2$$



**Radice dell'errore quadratico medio (RMSE)**


E' la radice quadrata del MSE.






Radice dell'errore quadratico medio  
(RMSE)

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^N (y_i - f(x_i))^2}$$



Radice dell'errore quadratico medio  
(RMSE)

$$RMSE = 2.31$$



## Radice dell'errore quadratico medio (RMSE)

Estraendo la radice riportiamo il valore sulla stessa scala dei residui.

# Fondamenti di Machine Learning

La Regressione

## **Il Coefficiente di Determinazione**

presentato da  
Giuseppe Gullo

PROFESSION 

Le metriche studiate finora  
ritornano valori che vanno sempre rapportati  
alla magnitudine della variabile target.

## Coefficiente di determinazione ( $R^2$ )

Ritorna un valore **standardizzato**.

Le metriche studiate finora  
ritornano valori che vanno sempre rapportati  
alla magnitudine della variabile target.

$$MAE = 2.075 \quad \bar{y} = 19.37$$

$$MSE = 5.35 \quad y_{\max} = 30$$

$$RMSE = 2.31 \quad y_{\min} = 10$$

## Coefficiente di determinazione (R2)

Somma dei quadrati residui (RSS)

$$RSS = \sum_{i=1}^N (y_i - f(x))^2$$



## Coefficiente di determinazione (R2)

Somma dei quadrati totali (SST)

$$SST = \sum_{i=1}^N (y_i - \bar{y})^2$$


## Coefficiente di determinazione ( $R^2$ )

$$R^2 = 1 - \frac{RSS}{SST}$$


## Coefficiente di determinazione (R<sup>2</sup>)

$$R^2 = 1 - \frac{RSS}{SST}$$

- **R<sup>2</sup> < 0.3** il modello è inutile.
- **0.3 < R<sup>2</sup> < 0.5** il modello è scarso.
- **0.5 < R<sup>2</sup> < 0.7** il modello è discreto.
- **0.7 < R<sup>2</sup> < 0.9** il modello è buono.
- **0.9 < R<sup>2</sup> < 1** il modello è ottimo.
- **R<sup>2</sup> = 1** molto probabilmente c'è un errore nel modello.



x	y	previsione
80	16	18.3
150	30	29.5
30	12	10.3
50	10	13.5
120	24	24.7
60	18	15.1
110	20	23.1
110	25	23.1



x	y	previsione
80	16	18.3
150	30	29.5
30	12	10.3
50	10	13.5
120	24	24.7
60	18	15.1
110	20	23.1
110	25	23.1

$$\bar{y} = 19.37$$

x	y	previsione
80	16	18.3
150	30	29.5
30	12	10.3
50	10	13.5
120	24	24.7
60	18	15.1
110	20	23.1
110	25	23.1

$$\bar{y} = 19.37$$

$$RSS = 42.8$$

$$SST = 321.87$$

$$R^2 = 0.87$$

# Fondamenti di Machine Learning

La Regressione

## **La Regressione Lineare Multipla**

presentato da  
Giuseppe Gullo

PROFESSION 

# La regressione lineare multipla


Ci permette di trovare una relazione lineare tra due o più variabili indipendenti (feature) e una variabile dipendente (target).




## Dataset di monolocali con 2 feature

Metri quadri	Anno di costruzione	Valore in €
80	1995	160.000
150	1995	300.000
30	2008	120.000
50	1996	100.000
120	1994	240.000
60	2006	180.000
110	1989	200.000
110	2000	250.000

## Dataset di monolocali con 2 feature



## Dataset di monolocali con 2 features



# La regressione lineare multipla

2 feature

$$y = w_1x_1 + w_2x_2 + b$$

Parametri del modello

$$w_1, w_2, b$$

# La regressione lineare multipla

3 feature

$$y = w_1x_1 + w_2x_2 + w_3x_3 + b$$

Parametri del modello

$$w_1, w_2, w_3, b$$

# La regressione lineare multipla

Visualizzare un dataset con 3 feature



# La regressione lineare multipla

N feature

$$y = w_1x_1 + w_2x_2 + w_3x_3 + \dots + w_Nx_N + b$$

Parametri del modello

$$w_1, w_2, w_3, \dots, w_N, b$$

# La regressione lineare multipla

Rappresentazione compatta

$$y = \sum_{i=1}^N w_i x_i + b$$



# La regressione lineare multipla

Rappresentazione vettoriale

$$y = W \cdot X + b$$

$$W = [w_1, w_2, w_3, \dots, w_N]$$

$$X = [x_1, x_2, x_3, \dots, x_N]$$

# La regressione lineare multipla

Rappresentazione vettoriale

$$y = \boxed{W \cdot X} + b$$

  
PRODOTTO SCALARE

## Prodotto Scalare

Dot Product

Il prodotto scalare tra due vettori  
che hanno la stessa dimensione  
si esegue sommando il prodotto  
degli elementi alla stessa posizione  
dei due vettori

$$[3 \ 5 \ 2 \ 7 \ 1] \bullet \begin{bmatrix} 4 \\ 2 \\ 6 \\ 1 \\ 5 \end{bmatrix} = 3*4 + 5*2 + 2*6 + 7*1 + 1*5 = 46$$

# La regressione lineare multipla

Altra rappresentazione vettoriale

$$y = W \cdot X$$

$$W = [w_0, w_1, w_2, w_3, \dots, w_N]$$


$$X = [1, x_1, x_2, x_3, \dots, x_N]$$

## Come si trovano i coefficienti di una regressione lineare multipla?

Possiamo usare il metodo dei minimi quadrati, ma diventa computazionalmente dispendioso al crescere del numero delle feature.

# Algoritmi di ottimizzazione iterativi

Minimizzano una funzione tramite una serie di step, in cui i parametri vengono spinti verso i valori che permettono di ottenere il minimo.



Algoritmo Gradient Descent

```
w = rand()
```

# Algoritmi di ottimizzazione iterativi

Minimizzano una funzione tramite una serie di step, in cui i parametri vengono spinti verso i valori che permettono di ottenere il minimo.

Gradient Descent

Stochastic

Gradient Descent

ADAM

RMSprop

Adadelta

Adagrad

Adadelta

# Fondamenti di Machine Learning

La Regressione

## **La Regressione Polinomiale**

presentato da  
Giuseppe Gullo


PROFESSION 



# La regressione lineare polinomiale

Ci permette di trovare una **relazione non lineare** tra una o più variabili indipendenti (feature) e una variabile dipendente (target) tramite un **polinomio**.


## La regressione lineare semplice



Polinomio di primo grado

$$y = wx + b$$

## La regressione lineare polinomiale




**Polinomio di secondo**

**grado**


$$y = w_1x + w_2x^2 + b$$

## La regressione lineare polinomiale



### Polinomio di terzo grado


$$y = w_1x + w_2x^2 + w_3x^3 + b$$



## Polinomio di quarto grado

$$y = w_1x + w_2x^2 + w_3x^3 + w_4x^4 + b$$


## La regressione lineare polinomiale



### Polinomio di quinto grado

$$y = w_1x + w_2x^2 + w_3x^3 + w_4x^4 + w_5x^5 + b$$

## a regressione lineare polinomiale



### Polinomio di ottavo grado

$$y = \sum_{i=1}^8 w_i x_i + b$$

## Attenzione

Anche se la relazione è non lineare,  
il modello polinomiale è comunque lineare.

$$y = w_1x + w_2x^2 + b$$



## Attenzione

Anche se la relazione è non lineare,  
il modello polinomiale è comunque lineare.

$$y = w_1x + w_2x^2 + b$$

I coefficienti del modello sono sempre di grado 1.

## Attenzione

Anche se la relazione è non lineare,  
il modello polinomiale è comunque lineare.

$$y = w_1x + w_2x^2 + b$$

Stiamo creando solo nuove features,  
che vengono chiamate **features polinomiali**.